


천라지망 기술 Q&A 대비 자료

본선 질의응답에서 "이 프로그램이 왜 이렇게 계산하는가"를 팀원이 직접 설명하기 위한 학습 자료다. 수식과 알고리즘 이름은 영어로 두고, 설명은 한국어로 쓴다. 모든 수치는 2026-09-20 기준 실제 코드(`backend/`)와 학습 결과(`models/fa9c4ef.../evaluation.json`)에서 가져왔다.

0. 30초 안에 말할 수 있어야 하는 문장

- 천라지망은 위치를 맞추는 AI가 아니라, 어디를 얼마나 믿을 수 있게 확인했는지 증명하는 도구다.
- 지도는 세 가지 가설(A: 학습된 거리 분포, B: 지형 시뮬레이션, B': 행동 규칙 변형)을 같이 돌려 만든다. 한 장의 정답 지도를 그리지 않는다.
- 수색 기록은 **POD (Probability of Detection)** 범위로 바뀌고, **Bayes' rule**로 "미발견" 증거만 지도에 반영한다.
- 학습한 것은 둘이다. 실제 실종 사건 65건의 발견 거리 분포(lognormal)와 수색대 GPS 61트랙의 이동 속도(Random Forest). 나머지는 가정이고, 앱이 표로 구분해 보여 준다.
- 검증은 **pre-registration**(기준을 먼저 적고 나중에 평가) 방식이고, 기준에 못 미친 모델 두 개는 미채택으로 남겼다.

1. 시스템 한눈에



버전이 바뀌는 순간은 딱 하나, 조정자가 "완료·미발견"을 확정할 때다. 업로드, 단서 기록, 계획 확정, 시간 미리보기는 지도를 바꾸지 않는다. 이 원칙이 "증명"의 핵심이다. 지도가 왜 이 모양인지 언제나 영수증(SHA-256)으로 거슬러 올라갈 수 있다.

2. 확률지도의 수학

2.1 확률 상태 (Distribution)

한 임무의 확률 상태는 `Distribution(grid, outside)` 다.

- `grid`: 512 × 512 배열. 셀 하나는 30 m × 30 m. 셀 (i, j)의 값은 대상이 그 셀에 있을 확률 p_{ij} . 이 확률은 제주도 전체 3,200 × 2,368 마스터 격자에서 마지막 확인 위치를 중심으로 64셀 격자점에 맞춰 잘라낸다 (`core.Master.window_origin`). 원래의 한림읍 창은 마스터의 (704, 448) 위치에 그대로 들어 있다.
- `outside`: 격자 밖 + 모형 밖(ROW)에 있을 확률.
- **불변식 (invariant)**: $\sum_{ij} p_{ij} + \text{outside} = 1$. 모든 연산 뒤에 `check()` 가 이 식을 검사한다(허용 오차 $1e-8$). 음수·NaN도 금지.

왜 `outside` 를 따로 두는가. 확률을 격자 안으로 억지로 정규화하면 "지도 밖에 있을 리 없다"는 가정이 몰래 들어간다. 지도 밖 몫을 숫자로 유지해야 "낮은 확률은 부재의 증거가 아니다"를 계산으로 지킬 수 있다.

2.2 시나리오 A — 학습된 발견 거리 분포 (lognormal)

정의. 확률변수 R (마지막 확인 위치에서 발견점까지의 거리)이 $\text{lognormal}(\mu, \sigma)$ 이라는 것은 $\ln R \sim \text{Normal}(\mu, \sigma^2)$ 라는 뜻이다. 확률밀도함수는

$$f(r) = 1 / (r \sigma \sqrt{2\pi}) \cdot \exp(-(\ln r - \mu)^2 / (2\sigma^2)), r > 0.$$

scipy 표기로는 `lognorm(s=σ, loc=0, scale=e^μ)`. 학습 결과(`endpoint.json`): $s = 0.6948$, $\text{scale} = 2436.9 \text{ m}$.

왜 lognormal인가. 거리는 항상 양수이고, 대부분은 몇 km 안에서 발견되지만 가끔 수십 km 사례가 있다(오른쪽 꼬리가 길다). 이런 "양수 + 오른쪽 꼬리" 자료의 표준 모델이 lognormal이다. 대안으로 Rayleigh(2차원 정규 분포의 반지름 분포)도 같이 적합했는데, 사건 하나씩 제외한 교차검증 NLL이 lognormal 8.877 < Rayleigh 9.039로 lognormal이 더 나왔다.

적합 (Maximum Likelihood Estimation). 65개 거리 $r_1 \cdots r_{65}$ 에 대해 $\ln r_i$ 의 표본평균이 $\hat{\mu}$, 표본표준편차가 $\hat{\sigma}$ 이다(lognormal의 MLE는 로그를 취한 뒤 정규분포 MLE와 같다). 이 결과 $\text{median} = e^{\hat{\mu}} = 2437 \text{ m}$.

분위수 반경 공식. 누적확률 q 에 해당하는 반경은

$$r_q = \text{scale} \cdot \exp(s \cdot \Phi^{-1}(q)), \Phi^{-1} \text{은 표준정규분포의 quantile function.}$$

$$r_{0.8} = 2437 \cdot \exp(0.6948 \times 0.8416) \approx 4.37 \text{ km}, r_{0.95} = 2437 \cdot \exp(0.6948 \times 1.645) \approx 7.64 \text{ km}.$$

검증 수치의 의미. "80% 반경 안에 실제 발견점이 들어온 비율 72.3%"는 leave-one-case-out으로, 사건 하나를 빼고 64건으로 적합한 뒤 그 사건의 발견점이 80% 반경 안에 있는지 센 것이다. 이상적으로 보정(calibrated)됐다면 80%여야 한다. 72.3%는 조금 좁게 예측한다는 뜻이고, 그래서 "보정 완료"라고 말하지 않는다.

도달 가능 반경 절단 (reach cap). 65건 자료에는 경과 시간이 없다. 그래서 경과시간 t 에 걸어서 갈 수 없는 거리 ($r > 5 \text{ km/h} \times t$)는 표본에서 제외(rejection sampling)하고 나머지를 다시 정규화한다. 이것은 시간 정보를 "없는 데서 만들어내는" 것이 아니라, 물리적으로 불가능한 부분만 잘라내는 최소한의 처리다.

격자로 옮기기. 거리 r 을 뽑고 방향 $\theta \sim \text{Uniform}(0, 2\pi)$ 를 뽑아 $(r \cos \theta, r \sin \theta)$ 를 마지막 확인 위치에 더한다. 위치 불확실성 σ_{pos} (기본 50 m)의 정규 난수도 더한다. 10만 개 표본을 셀별로 세어 히스토그램을 만든다. 방향을 균등으로 두는 이유는 학습 자료에 방향 정보가 없기 때문이고, 지형에 따른 방향 선호는 B가 담당한다.

한계(반드시 먼저 말할 것). 미국 하이커 표본이고, 원 논문이 1 km 미만 사건을 대부분 제외했다. 따라서 근거리 확률을 낮게 볼 수 있다(모델의 $P(R < 1 \text{ km}) \approx 10\%$). 우리는 이를 감추지 않고 근거리는 B/B'가 담당하도록 설계했다.

2.3 시나리오 B — 지형 몬테카를로 (Monte Carlo particle simulation)

Tobler's hiking function. 경사 $S = dh/dx$ (높이 변화/수평 거리, 무차원)에서 보행 속도는

$$v(S) = 6 \cdot \exp(-3.5 \cdot |S + 0.05|) \text{ km/h} = 1.667 \cdot \exp(-3.5 \cdot |S + 0.05|) \text{ m/s}.$$

평지($S=0$)에서 $6 \cdot e^{(-0.175)} \approx 5.04 \text{ km/h}$, 약간 내리막($S=-0.05$)에서 최대 6 km/h , 오르막 $S=0.2$ 에서 $6 \cdot e^{(-0.875)} \approx 2.5 \text{ km/h}$. 1993년 Tobler가 경험 자료로 제안한 함수로, 지형 분석에서 널리 쓰인다.

이동비용 격자. 여기에 토지피복 계수(나무 0.48, 관목 0.65, 농경지 0.8, 도로 30 m 이내 1.05, 그 외 1.0)와 실종자 이동성 계수 0.42를 곱한다. 0.42는 "실종자는 등산객처럼 계속 걷지 않는다"는 팀 가정이다(학습 아님).

입자 시뮬레이션. 입자 20,000개가 마지막 확인 위치($\pm \sigma_{\text{pos}}$)에서 출발해 8방향 격자 위를 걷는다. 매 걸음:

1. 현재 방향에서 회전 $\Delta \in \{-2, -1, 0, +1, +2\}$ (45° 단위)를 확률 $[.14, .20, .32, .20, .14]$ 로 뽑는다.
2. 다음 셀까지의 소요 시간 $\tau = \text{거리} / v$. 남은 시간이 τ 이상이면 이동, 아니면 정지.
3. 수역이나 45° 초과 경사에 도착한 입자는 **종착(terminal)** 상태가 된다. 확률은 사라지지 않고 그 셀에 남는다. (통행 불가 $\neq$ 존재 불가. 물에 빠진 사람은 물에 있다.)
4. 격자를 벗어난 입자는 `outside` 로 센다.

시간 예산이 끝나면 입자 위치를 셀별로 세어 히스토그램을 만든다. seed를 고정하므로 같은 입력은 항상 같은 지도를 만든다(영수증에 seed 기록).

2.4 시나리오 B' — 행동 규칙 변형

같은 시뮬레이션(같은 seed)에 세 가지 선호를 켜다.

- 회전 분포를 $[.08, .14, .56, .14, .08]$ 로 바꿔 직진 성향을 높인다.
- 후보 이동을 확률 $\min(1, \exp(\text{favor}))$ 로 받아들인다. $\text{favor} = (\text{도로까지 거리 감소량})/90 - \text{경사} + \text{시설 인력}$. 도로에 가까워지고 내리막이며 시설 쪽이면 $\text{favor} > 0 \rightarrow$ 항상 이동. 반대면 확률적으로 거절하고 30초를 소비한다(멈춰 서서 망설이는 것에 해당).
- 시설 인력은 OSM 시설 630곳까지의 지형 이동비용으로 만든 퍼텐셜 장의 기울기다(`facilities.py`). 강도는 0~1 조절, 기본 0.6.

B와 B'는 독립 모델이 아니라 **연관 시나리오**(같은 난수)다. 그래서 두 결과의 차이는 순전히 행동 규칙 때문이지 난수 때문이 아니다.

2.5 종합 지도와 합의 규칙

종합 표시: $P_{\text{mix}} = \frac{1}{2} A + \frac{1}{4} B + \frac{1}{4} B'$ (가중치는 팀 가정, 영수증에 기록).

구역 순위는 세 시나리오의 구역 확률 $m_A, m_B, m_{B'}$ 의 **기하평균 (geometric mean, log-linear pooling)**으로 정한다.

$$\text{score} = (m_A \cdot m_B \cdot m_{B'})^{(1/3)}.$$

왜 평균이나 최소값이 아닌가.

- 산술평균(=종합 지도 값)은 한 시나리오만 아주 크면 나머지가 0이어도 높다. "여러 가설에서 모두 유효한 곳" 원칙에 어긋난다.
- 최소값은 세 가설이 모두 유효해야 하지만, 가장 비관적인 한 가설이 순위를 완전히 지배한다. 학습된 A는 근거리를 낮게 보므로(2.2 한계) 최소값 규칙에서는 마지막 확인 위치 근처가 무조건 밀린다.
- 기하평균은 어느 하나가 0이면 0이 되어 "모두 유효" 조건을 지키면서, 한 가설의 비관이 전체를 지배하지 않는다. log를 취하면 세 로그확률의 평균이라 **log-linear pooling**이라고 부른다.

카드에 표시하는 **합의도 (agreement)** = min / max. 1에 가까우면 세 가설이 같은 값을 주고, 0에 가까우면 어느 한 가설이 반대한다는 뜻이다.

2.6 ROW — 모형 밖 잔여확률 (Rest of World)

수색 이론에서는 계획한 구역 어디에도 없을 확률을 ROW로 따로 둔다. 차량으로 이동했거나, 신고된 마지막 위치가 틀렸거나, 모형이 상상하지 못한 경우다. 천라지망은 임무 생성 시 row(기본 10%, 0~50% 조절)를 떼어

$grid \leftarrow (1 - row) \cdot grid, outside \leftarrow row + (1 - row) \cdot outside$

로 예약한다(`with_row`). 왜 필요한가. 임무 창은 한 번 15.36 km라 8시간 걸어도 창을 벗어나기 어렵다. ROW가 없으면 "지도 밖 0.00%"가 뜨는데, 이는 "밖에 없다"가 아니라 "모형이 밖을 상상하지 않았다"는 뜻일 뿐이다. ROW를 두면 아래 2.7의 갱신에서 수색이 실패할수록 ROW가 자동으로 커진다.

2.7 Bayes 갱신 — 미발견 증거

셀 x 에 대상이 있을 사전확률 $p(x)$, 그 셀의 탐지강도 $C(x)$ (3장), 셀에 대상이 있는데 못 찾을 확률 = $e^{-C(x)}$ (3.1에서 유도). "수색했는데 못 찾았다"는 사건을 N 이라 하면 Bayes' rule:

$p(x | N) = p(x) \cdot P(N | x) / P(N) = p(x) \cdot e^{-C(x)} / Z, Z = \sum_y p(y) e^{-C(y)} + outside.$

ROW·격자 밖 뒤편은 수색하지 않았으므로 $P(N | outside) = 1$, 분자가 그대로 $outside$ 다. 그래서 $Z < 1$ 이 되어 $outside/Z > outside$, 즉 **수색이 실패하면 지도 밖 확률이 커진다**. 코드 `update()` 가 정확히 이 식이고, 결과가 다시 `check()` 를 통과한다.

증명(질량 보존). $\sum_x p(x)e^{-C(x)}/Z + outside/Z = (\sum_x p(x)e^{-C(x)} + outside)/Z = Z/Z = 1. \blacksquare$

왜 승인된 기록만 반영하는가. 업로드된 기록이 "수색을 끝냈고 못 찾았다"는 사실을 담보하지 않기 때문이다. 중간에 멈췄거나, 다른 팀 기록일 수도 있다. 사람이 N 을 확정해야 Bayes 갱신의 조건(사건 N 이 실제로 일어남)이 성립한다.

3. 탐지확률 (POD)의 수학

3.1 Sweep width와 random search formula

Sweep width W (Koopman). 수색자가 지나갈 때 좌우로 유효하게 탐지하는 폭. 실제 탐지는 거리에 따라 확률이 줄지만, "그 확률 곡선의 면적"을 하나의 폭으로 요약한 것이 W 다. 문헌의 육상 수색 W 는 대상·식생에 따라 수 m 에서 수십 m 라서 우리는 8·15·22 m 세 가지를 가정으로 쓴다.

Coverage. 면적 A인 구역을 총 길이 L만큼 걸으면 coverage $C = W \cdot L / A$. $C = 1$ 이면 "폭 W로 구역을 정확히 한 번 훑을 만큼의 노력"이다.

Random search formula 유도. 수색 경로가 구역 안에서 충분히 무작위하다고 하자. 대상이 있는 지점을 수색자의 탐지 폭이 덮는 횟수는 평균 C인 Poisson 분포를 따른다(길이 L을 잘게 나눈 조각 각각이 그 지점을 덮을 확률이 작고 독립). Poisson(C)에서 0회일 확률은 e^{-C} . 따라서

$$POD = 1 - e^{-C}.$$

$C = 1$ 이면 $POD = 63\%$, $C = 2$ 면 86% . 완벽한 평행 수색이면 $C = 1$ 에서 100% 가 되겠지만, 실제 팀은 흔들리고 겹치므로 e^{-C} 가 보수적이고 현실적이다. (Koopman 1946, 미 해군 수색 이론.)

3.2 GPS 트랙 → 셀 탐지강도 $C(x)$


1. 인접 두 점 사이 구간마다 길이와 시간차를 계산한다. 시간차 > 120 초는 공백(GPS 끊김)으로 제외, 속도 < 0.08 m/s 또는 > 3 m/s 또는 길이 > 250 m는 비정상적으로 제외한다. 제외 구간에는 실선을 긋지 않는다.
2. 구간을 5 m 조각으로 나눠 각 조각의 길이를 주변 4개 셀에 bilinear 가중으로 나눠 준다. 이렇게 셀별 "걸은 길이" $\ell(x)$ 를 모은다.
3. $effort(x) = \ell(x) / (30 \text{ m} \times 30 \text{ m})$. 이것을 GPS 오차 $\sigma = 10$ m의 Gaussian kernel로 부드럽게 한다. 커널은 정규화되어 있어서 **총 노력의 합은 변하지 않는다**(노력을 옮길 뿐 새로 만들지 않는다).
4. $C_W(x) = W \cdot effort(x)$, $W \in \{8, 15, 22\}$. 세 배열을 저장하고, 지도 갱신에는 가운데 15 m를, 표시에는 8 m(하한)·22 m(상한)를 쓴다.

효과 확인: 30 m 셀 한 칸을 정확히 한 번 가로지르면 $\ell = 30$ m, $effort = 30/900 = 1/30$ /m, $C_{15} = 0.5 \rightarrow POD 39\%$. 두 번 지나면 $C = 1 \rightarrow 63\%$.

3.3 팀 밴드 (team band)

기록한 사람 옆에 $(n - 1)$ 명이 간격 s 로 나란히 걸었다면:

- 총 탐지 노력은 n 배: 각 대원이 자기 W 를 갖고 걷는다.
- 노력은 폭 $b = (n - 1) \cdot s$ 에 퍼진다. 폭 b 의 균일분포의 분산은 $b^2/12$ (증명: 구간 $[-b/2, b/2]$ 에서 x^2 의 평균 $= (1/b) \int x^2 dx = b^2/12$). 그래서 GPS 커널의 $\sigma^2 = 10^2 + b^2/12$ 로 넓혀 옆으로 퍼뜨린다.
- 가정: 기록자가 밴드 가운데를 걸었고, 밴드 안 밀도가 균일하다. 이것을 앱과 보고서에 "가정"으로 표시한다.



계획기에서는 같은 가정을 격자로 옮긴다. 밴드가 $k = \text{round}(b / 30)$ 행을 덮으면(최소 1), 팀은 k 행마다 한 번씩 잔디깎기 패턴으로 걷고 각 행에 n/k 배의 노력을 준다. $6\text{명} \cdot 15 \text{ m} \rightarrow k = 2 \rightarrow$ 한 번 지나갈 때 행 두 줄이 $C_{15} = 15 \cdot (6/2) / 30 = 1.5 \rightarrow POD 78\%$. 그래서 6명 팀은 480 m 구역을 60분에 훑고, 혼자서는 같은 시간에 열 몇 줄만 훑는다.

3.4 구역 POD와 표시 범위

구역 z 의 POD는 사전확률로 가중한 셀 탐지확률이다.

$$\text{POD}_z = \sum_{\{x \in z\}} p(x)(1 - e^{-C(x)}) / \sum_{\{x \in z\}} p(x).$$

"이 구역에 있었다면 찾았을 확률"이다. 8 m로 계산한 값을 하한, 22 m 값을 상한으로 보여 준다. 이것은 **가정에 따른 범위**이지 통계적 신뢰구간이 아니다. 질문이 나오면 이 구분을 분명히 말한다.

3.5 독립성 가정과 한계

서로 다른 수색 회차의 탐지는 조건부 독립이라고 가정한다(강도가 더해진다). 같은 좌표 경로를 다시 올리면 중복으로 차단한다. 실제로는 같은 팀이 같은 실수를 반복하거나(상관), 첫 수색이 흔적을 남겨 두 번째가 쉬워지는 일 있다. 이 보정은 실측 자료가 있어야 가능하고, 그것이 본선 전 모의 수색 실험의 목적이다.

4. 시간 추정

4.1 가중 질량 패킷과 일관된 난수

저장된 사후분포의 각 점유 셀에서 가중 경로 두 개를 출발시킨다(질량의 절반씩). 입자를 다시 무작위로 뽑지 않으므로 $t = 0$ 에서 표본 잡음이 없다. 난수는 (토큰, 걸음 수, seed, salt)를 섞은 counter-based hash로 만든다. 그래서 +30분과 +120분을 따로 계산해도 처음 30분의 경로가 같다 — 시간 슬라이더를 움직일 때 지도가 무작위로 흔들리지 않는다.

4.2 낮·밤 계수

태양고도를 NOAA 공식으로 분 단위 계산해 밤이면 이동에 쓰는 시간에 계수 0.6(조절 가능)을 곱한다. 즉 밤 60분은 낮 36분어치만 걷는다. 계수 자체는 가정이다.

4.3 관찰 시각 재생

실종·기준 시각이 있는 임무에서는 승인된 GPX를 관찰 시각 순서로 60초 구간에 묶고, 경로를 앞으로 굴리면서 각 구간 시각에 그 위치의 탐지강도만큼 생존 가중치를 깎는다:

$$w \leftarrow w \cdot \exp(-C_t(x_t)).$$

승인 버튼을 누른 시각이나 업로드 순서는 결과에 영향이 없다(파일 바이트로 정렬). 미래 관찰을 과거 화면에 쓰지 않는다.

5. AI 계획

5.1 수색대 속도 모델 (Random Forest regression)


- 자료: 실제 수색 사건의 수색대 GPS 61트랙, 45,141구간 중 44,285구간(공백·비정상·경사 결측 제외).


- 입력 특성 4개: |경사|, 그리고 수색 방식 one-hot (hasty, sweep, paired). 목표: 구간 속도 m/s.
- **Random Forest**: 결정트리(decision tree) 64개를 서로 다른 부트스트랩 표본으로 학습해 예측을 평균하는 앙상블. 트리 하나는 특성 임계값으로 자료를 반복 분할해 앞마다 평균 속도를 저장한다. 평균을 내면 분산이 줄어 과적합이 완화된다.
- 평가: **GroupKFold**로 team_id 8묶음을 나눠, 평가 팀의 구간이 학습에 절대 들어가지 않게 했다. 행 단위 무작위 분할을 하면 같은 사람의 인접 구간이 학습·평가 양쪽에 들어가 성능이 부풀려진다(data leakage).
- 결과: 트랙별 MAE 0.253 m/s. 비교 기준(방식별 중앙값 상수) 0.279 m/s. 9% 개선이며 크지 않다 — 이 모델의 역할은 "경사가 심하면 얼마나 느려지는가"를 자료로 정하는 것이지, 정확한 속도 예측이 아니다.
- 배포: 학습된 트리를 JSON으로 내보내고 서버는 NumPy로 직접 순회한다. pickle을 쓰지 않는 이유는 pickle이 임의 코드를 실행할 수 있기 때문이다. sklearn 원본 예측과 전체 학습 입력에서 최대 차이 0을 확인했다.

5.2 최단시간 경로 (Dijkstra's algorithm)

$512 \times 512 = 262,144$ 개 셀을 노드로, 4방향 인접을 간선으로 둔다. 간선 비용 = $30 \text{ m} / v$, v 는 RF 속도(경사별 표, 0.001 단위 양자화) $\times$ 토지피복 계수, 0.05~1.5 m/s로 절단. 수역·30° 초과 경사·자료 없음 셀은 노드에서 제외한다(위험 셀 통과 금지, 대각선 통과 금지). 출발 셀에서 모든 셀까지의 최단시간을 Dijkstra로 한 번 계산하면 (scipy.sparse.csgraph) 모든 후보 구역의 이동·복귀 시간을 바로 읽을 수 있다.

5.3 후보 선택과 탐욕 알고리즘 (greedy)





- gain은 시나리오마다 따로 계산하고 **가장 낮은 시나리오 값**을 쓴다(세 가설 모두에서 의미 있는 경로만 좋게 본다).
- 앞 팀이 훑은 셀은 $e^{(-\text{기준 } C)}$ 만큼 가치가 줄어 뒤 팀은 자연스럽게 다른 곳으로 간다(diminishing returns).
- 전역 최적(global optimum)이 아니다. 팀 4개 $\times$ 후보 32개 $\times$ 패턴 2개를 순서대로 고르는 탐욕 근사이며, 이 사실을 결과 JSON의 `assumptions`에 적는다.

5.4 이동 표적 계획 (coherent timed paths)

시간 미리보기 상태에서는 4.1의 가중 경로를 15초 간격으로 기록해 두고, 수색대가 셀 x 를 방문하는 시각 t 에 **그 시각에 x 에 있는 경로들의 가중치**만 탐지효과로 센다. 같은 경로를 두 팀이 다른 시각에 만나면 생존도 $e^{(-C_1)} \cdot e^{(-C_2)}$ 로 곱해 중복을 뺀다. 경로 수가 메모리 예산(256 MiB)을 넘으면 총화 표집하고 그 사실을 경고로 표시한다.

6. 학습 평가 방법론

- **NLL (negative log-likelihood)**: 평가 사건의 관측값에 모델이 준 확률밀도의 $-\log$. 낮을수록 좋다. 서로 다른 단위(연속 거리 vs 구간 vs 구역 질량)의 NLL은 직접 비교하지 않는다.
- **Leave-one-case-out**: 사건 65개 각각을 빼고 64개로 적합 $\rightarrow$ 뺀 사건 평가. 사건 단위 일반화를 본다.
- **Spatial block CV**: 위도·경도 1° 블록(65건) 또는 27개 공간 블록(YOSAR)으로 나뉘, 인접 사건이 학습·평가에 함께 들어가는 공간 누출을 막는다.
- **Bootstrap**: 블록을 복원추출해 2,000번 재계산한 차이의 분위수 범위. 범위가 0을 포함하면 "개선을 확신할 수 없다".
- **Pre-registration**: 채택 조건(예: "bootstrap 상한이 0 미만")을 학습 전에 문서(AI-**-사전검증계획.md)에 고정한다. 결과를 본 뒤 조건을 바꾸지 않는다. 그래서 지형 계수 모델(NLL 7.628 $\rightarrow$ 7.613, 범위 $-0.061 \sim +0.055$)과 GeoLife 보행 모델(평가 인원 5명)은 **NOT_ADOPTED**로 남았다. 이 두 결과는 실패가 아니라 "이 자료로는 이 결론을 내릴 수 없다"는 증거이며, 지우지 않고 앱의 구성요소 표에 그대로 보여 준다.

질문 "그럼 AI가 별로 한 게 없는 것 아닌가요?"에 대한 답: 학습이 바꾸는 것은 지도의 거리 척도(A)와 경로의 시간 척도(RF)다. 나머지는 확률 추론(Monte Carlo + Bayes)이고, 이 프로젝트의 주장은 "AI가 위치를 안다"가 아니라 "무엇을 알고 무엇을 모르는지 계산이 정직하다"이다. 데이터가 없는 곳에 학습을 억지로 넣지 않은 것이 설계다.

7. 데이터

자료	규모	출처·라이선스	쓰임
실제 실종 하이커 사건	65건, IPP·발견점 좌표	Hashimoto et al. 2022 Sci. Rep. 부록, CC BY 4.0	거리 분포 A 학습
수색대 GPS	61트랙, 45,141구간	Hashimoto et al. 2026 PLOS ONE, Zenodo 18637221, CC BY 4.0	속도 RF 학습
키프로스 훈련 GPS	9명, 4,011점	KIOS, Zenodo 6592419, CC BY 4.0	GPS 처리 품질검사
YOSAR 사건 키	132건(하이커 단일 끝점)	Doherty & Doke, CC BY-NC-SA 4.0	별도 참고 모델(선택)
지형	GLO-30 DEM, WorldCover 2021, OSM 도로 3,547·시설 630	Copernicus, ESA CC BY 4.0, ODbL	이동비용 격차

"국내 데이터는 왜 없나요?" → 마지막 위치와 발견 위치가 좌표로 공개된 국내 사례를 공개 자료에서 확보하지 못했다. 기사에서 추측해 채우지 않았다. 국내 사례 축적은 기관 협력이 전제인 다음 단계다.

8. 시스템과 보안

- **영수증(receipt):** 버전마다 코드 파일 해시, 지형 파일 해시, 가정, 파라미터, seed, 계산 배열 해시, 부모 버전 해시를 SHA-256으로 묶는다. 인계 ZIP의 manifest도 파일별 해시다. 해시는 "바뀌지 않았음"을 증명하지 "사실임"을 증명하지 않는다 — 이 문장을 보고서에도 넣었다.
- **로컬 전용:** 127.0.0.1에만 열고 Origin 검사, 업로드 2 MB 제한, GPX는 defusedxml로 파싱(XML 폭탄 방지), 모델은 JSON(pickle 금지).
- **역할:** 참여 코드는 SHA-256 해시로 저장, 봉사자 API는 확률 지도를 돌려주지 않음, 가족은 집계만. 인계 완료 시 원본 GPX를 `x''` (빈 값)으로 덮고 삭제 기록을 남긴다. 조정자 인증은 아직 없다(로컬 운영자 = 조정자).

9. 예상 질문과 답변

1. **"AI가 실종자를 찾아 주나요?"** 아니요. 어디를 얼마나 믿을 수 있게 확인했는지 계산하고 증명합니다. 위치를 단정하지 않습니다.
2. **"학습된 모델이 무엇인가요?"** 실제 실종 사건 65건의 발견 거리 lognormal과 수색대 61트랙의 속도 Random Forest, 두 가지입니다. 앱 안의 표에서 학습/가정을 구분해 보여 줍니다.
3. **"왜 65건뿐인가요? 딥러닝은요?"** 좌표가 공개된 실제 사건이 그만큼뿐입니다. 65건에 신경망을 쓰면 과적합이고, 2-파라미터 분포가 정직한 선택입니다.
4. **"72.3%는 좋은 건가요?"** 80% 반경의 이상값은 80%입니다. 72.3%는 조금 좁게 예측한다는 뜻이라 "보정 전"이라고 표시합니다.

5. **"미국 데이터를 한국에 써도 되나요?"** 그대로 맞다고 주장하지 않습니다. 근거리는 지형 시뮬레이션이 보완하고, 국내 사례 축적이 다음 단계입니다.
6. **"세 시나리오를 왜 섞나요?"** 한 모델을 과신하지 않기 위해서입니다. 겹치는 곳은 확신, 갈리는 곳은 불확실로 표시합니다.
7. **"순위는 어떻게 정하나요?"** 세 시나리오 구역 확률의 기하평균입니다. 하나라도 0이면 후보에서 빠집니다.
8. **"POD 8-20%는 너무 낮지 않나요?"** 혼자 걸은 기록이면 그렇습니다. 6명이 15 m 간격이면 같은 구역이 37-60%가 됩니다. 팀 인원·간격을 입력받는 이유입니다.
9. **"POD 범위가 신뢰구간인가요?"** 아닙니다. 탐지폭 8·22 m 가정에 따른 범위입니다. 실측 보정은 모의 수색 실험에서 합니다.
10. **"수색이 실패하면 확률이 어디로 가나요?"** 수색하지 않은 셀과 지도·모형 밖(ROW)으로 갑니다. Bayes 갱신의 분모가 작아져 자동으로 그렇게 됩니다.
11. **"업로드하면 바로 지도가 바뀌나요?"** 아니요. 조정자가 '완료·미발견'을 확정해야 바뀝니다. 업로드는 관측이 아닙니다.
12. **"단서·제보는요?"** 장부에만 기록합니다. 소문 하나가 지도를 옮기지 못하게 하려는 원칙입니다.
13. **"AI 계획이 최적인가요?"** 아닙니다. 왕복 가능한 후보 32개 안의 탐욕 선택입니다. 그 사실을 결과에 적습니다.
14. **"수색대 속도 모델이 9%밖에 안 좋아졌는데요?"** 맞습니다. 이 모델의 역할은 경사에 따른 감속을 자료로 정하는 것이고, 큰 정확도 향상을 주장하지 않습니다.
15. **"학습에 누출은 없나요?"** 사건 단위·공간 블록·팀 단위로 나눴습니다. 행 단위 무작위 분할은 하지 않았습니다. team_id가 사건 ID와 같지 않아 모든 누출을 배제했다고는 말하지 않습니다.
16. **"미채택 모델은 왜 보여 주나요?"** 채택 기준을 미리 정했고 그 결과가 증거이기 때문입니다. 숨기면 정직성 원칙이 무너집니다.
17. **"실시간 위치 추적은요?"** 없습니다. 봉사자가 기록을 제출하는 방식이고, 실시간 추적·교통 정보는 이번 범위 밖입니다.
18. **"개인정보는요?"** 동의 후 제출, 코드 해시 저장, 역할별 화면 제한, 인계 시 원본 삭제. 조정자 계정·암호화는 아직 없습니다.
19. **"왜 한림읍인가요?"** 처음 창을 한림읍에 둔 이유는 2026년 8월 사건이 일어난 지역 중 하나이고 농경지·해안·도로가 섞여 지형 시뮬레이션을 시험하기 좋아서입니다. 지금은 제주도 전체를 30 m 격자로 준비해 두고 임무마다 마지막 확인 위치 주변 15.36 km 창을 잘라 씁니다. 섬 전체를 한 번에 계산하지 않는 이유는 셀이 28배로 늘어 입자 시뮬레이션·Dijkstra·PNG 렌더링이 실시간성을 잃고, 8시간 도보 범위가 창 안에 들어오기 때문입니다.
20. **"기존 서비스와 뭐가 다른가요?"** SAROS는 기관용이고 봉사자 계층이 없습니다. FindSquad는 확률·POD 개념이 없습니다. 우리는 봉사자 GPS를 POD로 환산해 재현 가능한 인계 문서로 만듭니다.
21. **"Tobler 함수는 뭔가요?"** 경사에 따른 보행 속도 경험식입니다. $v = 6 \cdot \exp(-3.5|S+0.05|)$ km/h. 약간 내리막에서 가장 빠릅니다.
22. **" $1-e^{-C}$ 는 어디서 나왔나요?"** Koopman의 random search formula입니다. 탐지 횟수를 Poisson으로 보면 0회 확률이 e^{-C} 입니다.
23. **"ROW 10%는 근거가 있나요?"** 값 자체는 팀 가정입니다. 항목을 두는 것은 수색 이론의 관행이고, 값은 조절할 수 있으며 영수증에 남습니다.

24. "영수증이 진실을 보증하나요?" 아니요. 바뀌지 않았음을 보증합니다. 사실성·기관 승인·발급자 신원은 별개입니다.
25. "생성형 AI를 썼나요?" 예. 코드·문서 초안과 테스트 작성에 썼고, 문제 정의·데이터 선택·기준 선언·해석은 팀이 했습니다. 공개 문서가 있습니다.
26. "다음은 뭔가요?" 모의 수색 실험으로 POD 가정을 실측과 비교하는 것입니다. 그 전까지 이 도구는 훈련용입니다.
27. "실패한 게 있나요?" 두 모델이 채택 기준 미달이었고, 처음엔 팀 하나를 한 사람 경로로만 계산해 효과가 1%p로 나왔습니다. 팀 밴드를 넣어 고쳤습니다.
28. "가장 큰 한계는?" 실제 실종자의 시각별 궤적과 탐지 정답 자료가 없다는 것입니다. 그래서 '검증 전'이라는 말을 지우지 않습니다.
29. "응급 상황에 쓸 수 있나요?" 아직 아닙니다. 판단 보조·훈련용이며 안전 채널이 아닙니다.
30. "확장하면 돈은 어떻게?" 가족에게 받지 않습니다. 훈련용 배포 → 등록 단체 → 지자체 실증 순이고, 비상업 자료는 그 단계에서 끝니다.
-

10. 용어집

- **POA (Probability of Area)**: 대상이 특정 구역에 있을 확률. 이 앱의 "존재 가능성".
- **POD (Probability of Detection)**: 구역에 있었다면 찾았을 확률. $1 - e^{-C}$.
- **POS (Probability of Success)** = POA × POD.
- **Coverage C**: W·L/A. 탐지 노력의 밀도.
- **Sweep width W**: 유효 탐지 폭.
- **ROW (Rest of World)**: 계획 구역 어디에도 없을 확률.
- **IPP (Initial Planning Point)**: 마지막 확인 위치.
- **Prior / Posterior**: 관측 전/후 확률.
- **Lognormal**: 로그를 취하면 정규분포인 양수 분포.
- **Monte Carlo**: 난수로 표본을 만들어 분포를 근사하는 방법.
- **Random Forest**: 결정트리 앙상블 회귀.
- **GroupKFold / Leave-one-out**: 그룹(팀·사건) 단위로 학습·평가를 나누는 교차검증.
- **NLL**: negative log-likelihood, 낮을수록 좋은 예측 점수.
- **Pre-registration**: 평가 기준을 결과 전에 고정하는 것.
- **Dijkstra**: 비음수 가중 그래프의 최단경로 알고리즘.
- **Greedy**: 매 단계 최선을 고르는 근사 알고리즘.
- **Log-linear pooling**: 확률의 기하평균으로 여러 모델을 합치는 방법.